

Taller 4: Data Janitor 3000 (Limpieza y SQL)

Docente: Dudbil Olvasada Pabon Riaño

1. Objetivo del Taller

Enfrentar la realidad de los datos del mundo real: la suciedad y la inconsistencia. El estudiante aplicará técnicas de imputación estadística usando Pandas y ejecutará cruces lógicos simulando operaciones de bases de datos relacionales (SQL Joins).

2. Instrucciones Generales

Desarrolle los retos en un Jupyter Notebook. Para este taller necesitará generar los **DataFrames** de juguete propuestos usando diccionarios. Suba el documento a su repositorio documentando claramente por qué tomó cada decisión de limpieza.

Misión Analítica: El Rescate del CRM

Usted es el “Data Janitor” de una aerolínea. El equipo de reservas migró la base de datos antigua a un nuevo sistema, pero en el proceso, se generaron valores nulos (NaN), edades ilógicas y clientes duplicados. Si los modelos de Machine Learning entran en producción con esta basura, la empresa perderá millones.

Reto 1: Detectando la Basura Oculta (20 %)

Cree el siguiente DataFrame en Pandas usando este código:

```
import pandas as pd
import numpy as np

data = {
    'cliente_id': [101, 102, 103, 104, 105, 106, 101],
    'edad': [25, 30, np.nan, 800, 45, 22, 25],
    'genero': ['M', 'F', 'F', 'M', 'O', np.nan, 'M'],
    'millas': [1500, 2000, 50, 10000, np.nan, 300, 1500]
}
df = pd.DataFrame(data)
```

1. Utilice los métodos `.isnull().sum()` o `.info()` para contar exactamente cuántos valores nulos (NaN) tiene cada columna. Imprima el reporte.
2. **Análisis Crítico:** Observe el valor de la edad del cliente 104. ¿Es posible tener 800 años? Describa en una celda de texto cómo esta “anomalía semántica” (que no es un NaN) afectaría el promedio (media) de edades si la pasamos por alto.

Reto 2: Cirugía de Datos: Imputación (30 %)

No podemos simplemente eliminar filas porque perderíamos información valiosa de los clientes. Debemos “Imputar” (rellenar inteligentemente).

1. **Imputar Variables Numéricas:** Rellene el valor nulo de la columna `millas` utilizando la **mediana** de esa misma columna. (Pista: investigue el método `.fillna()`).
2. **Imputar Variables Categóricas:** Rellene el valor nulo de la columna `genero` utilizando la **moda** (el valor más frecuente) de la columna.
3. **Tratar Valores Absurdos:** Reemplace el valor absurdo de 800 en la edad por un NaN usando el método `.replace()`, y posteriormente impútelo usando la media de la edad. Muestre el DataFrame resultante.

Reto 3: Desduplicación (10 %)

Durante la migración, algunos registros de clientes se insertaron dos veces.

1. Utilice el método `.drop_duplicates()` de Pandas para eliminar filas idénticas.
2. ¿Cuántas filas quedaron en total después de eliminar los duplicados?

Reto 4: SQL en Pandas (El Arte del Join) (40 %)

Los datos demográficos ya están limpios, pero el área de fidelización tiene otra tabla separada con el nivel (Tier) de cada cliente. Cree este segundo DataFrame:

```
tier_data = {
    'cliente_id': [101, 102, 104, 105, 999],
    'nivel': ['Gold', 'Silver', 'Platinum', 'Silver', 'Gold']
}
df_tier = pd.DataFrame(tier_data)
```

1. Realice un **INNER JOIN** (cruce interno) entre su DataFrame limpio (`df`) y el nuevo DataFrame (`df_tier`) utilizando la columna `cliente_id` como llave primaria (*Key*). Utilice el método `pd.merge()`.
2. Realice un **LEFT JOIN** (cruce por la izquierda). Mantenga todos los clientes de su `df` original, cruzando con `df_tier`.
3. **Análisis Crítico:** Observe el resultado del Left Join. ¿Qué sucede con los clientes 103 y 106 en la columna `nivel`? ¿Por qué aparece un NaN ahí, y por qué el cliente 999 de la tabla de Tiers no aparece en absoluto? Explique la lógica de la teoría de conjuntos detrás de esto.

‘Tu modelo de Inteligencia Artificial solo es tan inteligente como los datos basura que le diste de comer (Garbage In, Garbage Out).’